Relatório Técnico – Fase 2: Tratamento, Modelagem e Armazenamento dos Dados

1. Identificação e resumo

Tema: Painel Epidemiológico de Mortalidade Materna e Violência Obstétrica

Integrantes: Alison Andrade Rocha, Lívia Alves de Souza e Vitor Carvalho Ferreira

Disciplina: Big Data e Analytics · ODS 5 (Igualdade de Gênero) e ODS 18 (Igualdade Étnico-Racial)

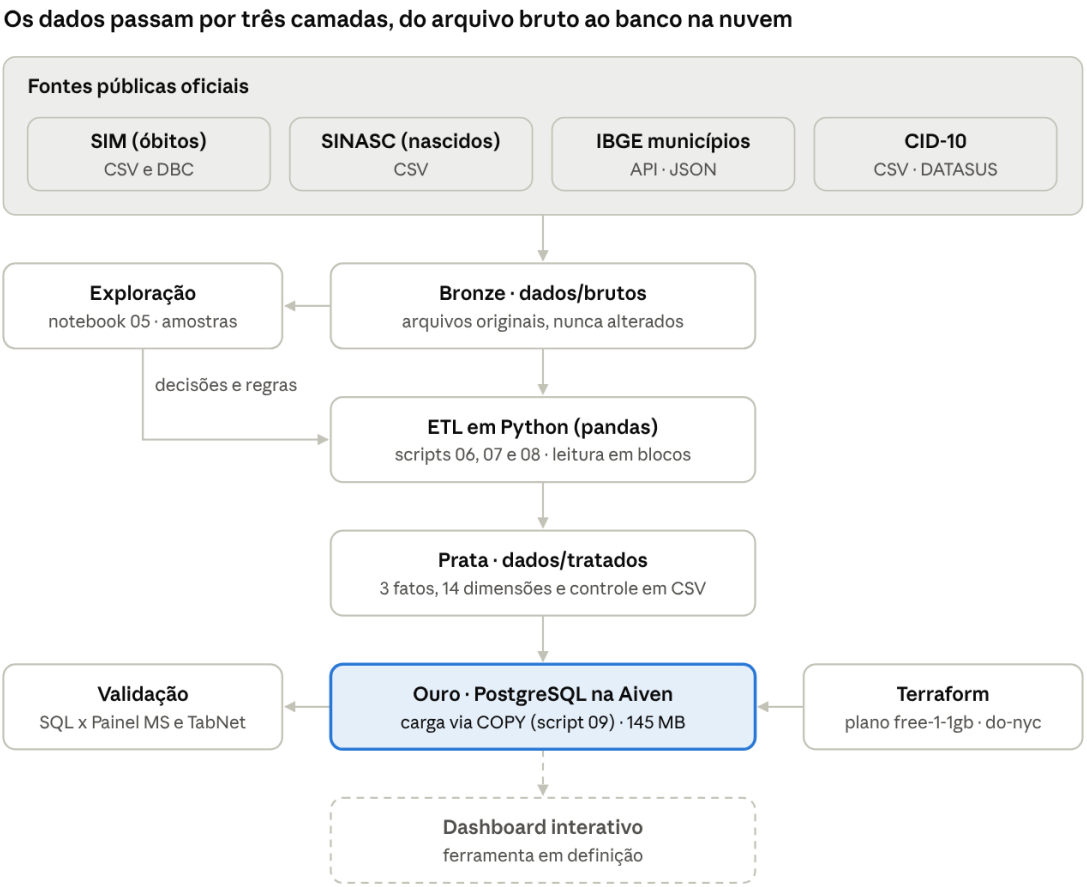
Os microdados do SIM e do SINASC de 2022 a 2024 foram tratados, validados contra fontes oficiais e armazenados em um PostgreSQL na nuvem (Aiven, plano gratuito), provisionado via Terraform. Os cerca de 7,5 milhões de nascimentos e 4,5 milhões de óbitos brutos (mais de 3 GB em CSV) ocupam 145 MB no banco, 14% do limite de 1 GB, sem perda de nenhum registro.

Principais resultados desta fase:

- **4.914 óbitos maternos** selecionados nos três anos, dos quais 4.020 entram no cálculo da Razão de Mortalidade Materna (RMM).
- **7.488.823 nascidos vivos** armazenados como contagens agregadas, idênticos ao TabNet/DATASUS nos três anos.
- **RMM de 53,5 (2022), 52,2 (2023) e 55,5 (2024)** por 100 mil nascidos vivos. Em 2024, o número de óbitos coincide exatamente com o Painel de Monitoramento do Ministério da Saúde, inclusive nas 27 UFs.
- **Modelo estrela** com 3 tabelas fato e 14 dimensões, com integridade referencial garantida por chaves estrangeiras.

2. Visão geral do pipeline

O pipeline segue a arquitetura em camadas (*medallion*): os arquivos brutos são preservados (bronze), o ETL gera tabelas limpas e tipadas (prata) e a carga as organiza no modelo estrela do banco (ouro).



arquitetura do pipeline · bronze, prata e ouro

O notebook de exploração não faz parte da execução regular: ele serviu para descobrir os problemas e validar as regras, que depois foram implementadas nos scripts. O banco é criado pelo Terraform antes da carga, e o script 10 confere os indicadores no banco contra as fontes oficiais.

3. Origem dos dados e versões utilizadas

Todas as fontes são públicas e oficiais. Os arquivos originais ficam em `dados/brutos/` (fora do GitHub, pelo tamanho) e nunca são alterados: todo tratamento gera novos arquivos.

Base	Ano	Arquivo original	Origem	Formato	Registros	Colunas
SIM (óbitos)	2022	DOBR2022.dbc	DATASUS – Transferência de Arquivos	DBC → CSV	1.544.266	87
SIM (óbitos)	2023	DOBR2023.dbc	DATASUS – Transferênci	DBC → CSV	1.465.610	87

Base	Ano	Arquivo original	Origem	Formato	Registros	Colunas
			a de Arquivos			
SIM (óbitos)	2024	DO24OPEN.csv	OpenDataSUS	CSV	1.532.015	88
SINASC (nascidos vivos)	2022	sinasc_2022.csv	OpenDataSUS	CSV	2.561.922	61
SINASC (nascidos vivos)	2023	sinasc_2023.csv	OpenDataSUS	CSV	2.537.576	62
SINASC (nascidos vivos)	2024	sinasc_2024.csv	OpenDataSUS	CSV	2.389.325	62
Municípios	atual	API de Localidades	IBGE	JSON	5.571	6 (após achatamento)
CID-10	2008	CID-10-SUBCATEGORIAS, CATEGORIAS, GRUPOS, CAPITULOS	DATASUS	CSV	12.451 subcategorias	—

Documentação de apoio: dicionário de dados do SIM (Estrutura do SIM, atualizado em 06/2025), estrutura do SINASC e protocolo de codificações especiais em mortalidade do Ministério da Saúde.

Classificação dos tipos de dados: os microdados do SIM e do SINASC são estruturados; a resposta da API do IBGE é semiestruturada (JSON aninhado, achatado em tabela no ETL); os dicionários de dados são documentos não estruturados (PDF), usados para decodificar as variáveis.

Em aberto: registrar a data de download de cada arquivo, que compõe a identificação da versão original.

4. Exploração dos dados no Jupyter Notebook

Antes de escrever o ETL, a equipe usou um Jupyter Notebook (`etl/fase2/05_exploracao_bases.ipynb`) para visualizar amostras, medir a completude das colunas e testar as regras sobre os dados reais. Essa etapa de *data profiling* embasou as decisões de tratamento, de modelagem e dos relacionamentos do banco.

Na atividade anterior (A02), a análise foi feita apenas com os arquivos de 2024. Com a inclusão de 2022 e 2023, foi necessário verificar se a estrutura dos arquivos se mantinha entre os anos, o que revelou o problema descrito na seção 5.

O notebook lê os arquivos em blocos (`chunksize`) e apenas com as colunas necessárias, para não carregar arquivos de mais de 500 MB inteiros na memória. As principais descobertas e as decisões que geraram:

Descoberta na exploração	Decisão tomada
O SINASC tem duas colunas de raça/cor: `RACACOR` (do recém-nascido) e `RACACORMAE` (da mãe)	Usar `RACACORMAE`, já que a análise é sobre as mulheres
O código `9` significa "ignorado" e não aparece como nulo para o pandas; o vazio também ocorre	Unificar vazio e `9` como "Ignorado" no ETL
As 100 primeiras linhas do SIM não têm nenhum óbito materno (são cerca de 0,1% do total)	Analisar as colunas do SIM sobre os casos filtrados, e não sobre a amostra inicial
O campo `CAUSAMAT` traz o código O93, que não existe na CID-10 internacional	Investigar e adotar a regra oficial do Ministério da Saúde (seção 6)
A variável `MAT_CLAS` separa exatamente os óbitos que entram na RMM	Usá-la só como validação, pois existe apenas em 2024 e não consta no dicionário oficial
25 códigos de causa básica não estavam na tabela CID-10 de 2008	Atribuir descrição em cascata: subcategoria, tabela manual (atualizações da OMS) e categoria
O arquivo do SIM de 2024 tem 88 colunas e os de 2022 e 2023, 87; o SINASC 2022 tem 61	Padronizar nomes em maiúsculas e ler só as colunas usadas, todas presentes nos três anos
No SINASC, o código 3 de `STCESPARTO` ("não se aplica") coincide com o número de partos vaginais	Confirmou a interpretação do campo de cesárea antes do trabalho de parto
Idade da mãe e consultas de pré-natal usam 99 como "ignorado"; há mães com menos de 10 anos	Tratar 99 como ignorado e manter a faixa "<10" visível

Também no notebook, a regra de seleção dos óbitos maternos foi comparada com os números oficiais antes de ser implementada no pipeline (seção 7).

5. Problema encontrado: SIM 2022 e 2023 sem cabeçalho

Os arquivos CSV do SIM de 2022 e 2023 disponíveis no OpenDataSUS vieram sem a linha de cabeçalho, por isso foram substituídos pelos arquivos DBC oficiais do DATASUS, que trazem os nomes das colunas.

O problema apareceu ao comparar as colunas dos três anos: o pandas leu a primeira linha de registros como se fosse o cabeçalho, gerando "colunas" com nomes como `*I219`, `04-05-2022` e `1230`, que são

códigos de causa, datas e horários. A leitura das linhas cruas confirmou outras diferenças em relação a 2024:

Característica	CSV 2022	CSV 2023	CSV 2024
Linha de cabeçalho	não tem	não tem	tem
Coluna `contador`	não tem	tem	tem
Formato de data	21-04-2022	14-02-2023	08112024
Hora	1230	930 (sem zero à esquerda)	1044

Colar o cabeçalho de 2024 nos outros anos não era seguro: o número de colunas difere e o arquivo de 2022 tem uma coluna a mais no meio. Um cabeçalho desalinhado faria o filtro ler a coluna errada sem gerar nenhum erro.

Solução adotada: os arquivos `DOBR2022.dbc` e `DOBR2023.dbc` foram obtidos na página de Transferência de Arquivos do DATASUS e convertidos para CSV com cabeçalho no próprio notebook, usando as bibliotecas `pyreaddbc` (descompactação) e `dbfread` (leitura). Nesse formato, as datas e horas seguem o mesmo padrão de 2024.

Como verificação, o cabeçalho do CSV de 2023 também foi deduzido comparando a distribuição de valores de cada coluna com o DBC, e os dois caminhos geraram exatamente o mesmo resultado (1.324 óbitos na RMM, idênticos por UF). Isso confirmou que o DBC e o CSV são a mesma versão da base. Ainda assim, optou-se pelo DBC, que traz os nomes oficiais das colunas sem depender de dedução.

O download automático pelo FTP do DATASUS foi tentado, mas a conexão de dados foi bloqueada pela rede; os arquivos foram baixados pela interface web.

6. Decisões de tratamento e justificativas

6.1 Seleção e classificação dos óbitos maternos (SIM)

A regra foi construída a partir da CID-10 e do protocolo de codificações especiais do Ministério da Saúde, e não de uma variável pronta, porque a `MAT_CLAS` só existe no arquivo de 2024.

São selecionados os óbitos femininos com causa básica no capítulo XV da CID-10 (O00 a O99) ou com o marcador O93 no campo `CAUSAMAT`. O O93 é uma adaptação brasileira que identifica óbitos maternos associados a causas externas (por exemplo, O93.0 para acidente de transporte).

Classificação	Critério	Entra na RMM	Óbitos 2022–2024
Materno	Causa básica de O00 a O99, exceto O96 e O97	Sim	4.020
Materno tardio	Causa básica O96 ou O97 (após 42 dias do parto)	Não	808

Classificação	Critério	Entra na RMM	Óbitos 2022–2024
Associado a causa externa	Causa básica fora do capítulo O, com marcador O93	Não	86

A exclusão dos tardios e das causas externas segue a definição oficial da RMM no Brasil. Em 2024, essa classificação coincidiu caso a caso com a `MAT_CLAS` (1.326 óbitos com valor 1; tardios e externos com valor 3). Entre os casos de causa externa há homicídios (O93.7) e suicídios (O93.6) de gestantes e puérperas, mantidos para um indicador complementar sobre violência.

6.2 Causas de óbito pela CID-10 oficial

Cada código recebe a descrição da tabela oficial do DATASUS, em cascata: subcategoria, depois uma tabela manual com dois códigos incluídos pela OMS após 2008 (O98.7, HIV na gravidez, e O14.2, síndrome HELLP) e, por fim, a categoria. As 269 causas usadas receberam descrição e o grupo oficial da CID-10.

6.3 Padronização e conversão de tipos

- **Ignorados:** vazio, nulo e código `9` são unificados como `9` ("Ignorado"); códigos fora do dicionário de dados também.
- **Idade (SIM):** o campo de 3 dígitos é decodificado em anos (primeiro dígito 4 = anos, 5 = mais de 100 anos; ex.: 425 = 25 anos).
- **Datas:** `DTOBITO` convertida de texto ddmmaaaa para data, com extração de ano e mês.
- **Grupo de Robson:** convertido de texto com zero à esquerda (`05`) para inteiro.
- **Código de município:** mantido como texto de 6 dígitos, para não perder zeros e permitir o relacionamento com o IBGE.
- **Faixas etárias:** as mesmas para a falecida (SIM) e para a mãe (SINASC), condição para calcular a RMM por idade.
- **Pré-natal:** número de consultas agrupado nas faixas usadas pelo Ministério (nenhuma, 1 a 3, 4 a 6, 7 ou mais).

6.4 LGPD e minimização de dados

Só as colunas necessárias à análise são lidas dos arquivos brutos. Foram descartadas, entre outras: data de nascimento da falecida e da mãe, código do estabelecimento de saúde, ocupação, naturalidade e horário do óbito e do nascimento. O estabelecimento, em especial, poderia ajudar a reidentificar uma pessoa em municípios pequenos.

6.5 Agregação do SINASC, sem amostragem

Os nascidos vivos são armazenados apenas como contagens, em duas tabelas com grãos diferentes:

- **Por município** (ano, município, faixa etária, raça/cor e escolaridade da mãe): denominador da RMM, com detalhamento até o município.
- **Por UF com variáveis do parto** (as mesmas dimensões, mais tipo de parto, grupo de Robson, faixa de pré-natal, cesárea antes do trabalho de parto e indução): base do eixo de violência

obstétrica. O detalhe obstétrico por município geraria grupos com 1 ou 2 partos, sem valor analítico.

Não foi usada amostragem estatística: com tantos cruzamentos, uma amostra eliminaria grupos inteiros. A agregação reduziu 7,5 milhões de registros a 1,26 milhão de linhas, e o script confere em cada ano que a soma das contagens é igual ao total de registros lidos.

6.6 Municípios ignorados

Nos dados há 19 códigos no formato UF + `0000` ("município ignorado", mesma convenção do TabNet), que não existem no IBGE. Eles foram incluídos na dimensão de municípios para que nenhum óbito ou nascimento se perca no relacionamento.

7. Validação com fontes oficiais

Os nascidos vivos coincidem exatamente com o TabNet nos três anos, e os óbitos maternos coincidem com o Painel de Monitoramento da Mortalidade Materna em 2024, com diferença máxima de 0,4% nos outros anos.

Ano	Óbitos (projeto)	Óbitos (Painel MS)	Diferença	Nascidos vivos (projeto)	Nascidos vivos (TabNet)	Diferença	RMM (por 100 mil NV)
2024	1.326	1.326	0	2.389.325	2.389.325	0	55,5
2023	1.324	1.319	+5 (0,4%)	2.537.576	2.537.576	0	52,2
2022	1.370	1.368	+2 (0,15%)	2.561.922	2.561.922	0	53,5

Filtros usados no painel: óbitos por residência, Brasil, indicador "Maternos declarados", categoria "Notificação de óbitos de mulheres", todos os grupos etários. No TabNet: Nascidos Vivos – Brasil, nascimentos por residência da mãe. Consultas em 03/10/2026.

Validação por UF: em 2024, as 27 UFs apresentaram diferença zero em relação ao painel. Em 2023, 22 das 27 UFs coincidem exatamente.

Origem das diferenças em 2022 e 2023: foram testadas e descartadas as hipóteses de erro no filtro (óbitos do capítulo O com sexo não feminino, causas especiais fora do capítulo O e momento do óbito). A diferença foi atribuída à versão da base: os arquivos DBC são uma fotografia do momento em que foram gerados, enquanto o painel é atualizado continuamente conforme os comitês concluem as investigações de óbito, que podem reclassificar casos.

Validações internas do pipeline:

- A soma das contagens agregadas do SINASC é igual ao número de registros lidos, em cada ano e nas duas tabelas.
- Todos os códigos usados nas tabelas fato existem nas dimensões (integridade referencial), conferido pelo script 08 e garantido no banco por chaves estrangeiras.
- As contagens de linhas no banco coincidem com os arquivos tratados em todas as 19 tabelas.

- Os indicadores foram recalculados no PostgreSQL com SQL (script 10), reproduzindo os mesmos valores.

Fontes: Painel de Monitoramento da Mortalidade Materna · TabNet/DATASUS

8. Processo de tratamento (entregável 2)

O processo é um pipeline em Python (pandas) com scripts numerados na ordem de execução, todos no repositório em `etl/`. Cada script lê o resultado do anterior, e as regras compartilhadas (caminhos, anos, faixas etárias, leitura em blocos) ficam em um único módulo, `comum.py`, para que nenhuma decisão seja implementada de dois jeitos.

Etapa	Arquivo	O que faz	Saída
Fase 1	`fase1/01` a `04`	Testes das APIs do Ministério da Saúde e extração dos municípios da API do IBGE	`dim_municipio_ibge.csv`
Exploração	`fase2/05_exploracao_bases.ipynb`	Perfil das bases, testes das regras, conversão DBC → CSV e validações	decisões documentadas
Tratamento SIM	`fase2/06_tratamento_sim.py`	Seleção e classificação dos óbitos maternos, decodificação e padronização	`fato_obito_materno.csv`, `controle_sim.csv`
Tratamento SINASC	`fase2/07_tratamento_sinasc.py`	Padronização e agregação dos nascidos vivos nas duas tabelas fato	`fato_nascidos_municipio.csv`, `fato_nascidos_parto.csv`, `controle_sinasc.csv`
Dimensões	`fase2/08_dimensoes.py`	14 tabelas de dimensão e checagem de integridade referencial	`dim_*.csv`
Carga	`fase2/09_carga_postgres.py`	Criação do schema e carga via `COPY` no PostgreSQL	tabelas no banco + `controle_carga`
Validação	`fase2/10_validacao_carga.py`	Indicadores recalculados em SQL e comparados com as fontes oficiais	relatório no terminal

Etapa	Arquivo	O que faz	Saída
Schema	`sql/01_schema.sql`	Tabelas, tipos, chaves primárias e estrangeiras	—

As tabelas `controle_sim` e `controle_sinasc` registram, para cada ano, o arquivo de origem, o tamanho, as linhas lidas, as linhas resultantes e a data do processamento, ligando a versão original à versão tratada.

Como executar (a partir da raiz do projeto, com os arquivos brutos em `dados/brutos/`):

1. Instalar as dependências: `pip install pandas requests dbfread pyreaddbc "psycopg[binary]"` (no Windows, o `pyreaddbc` exige o Microsoft C++ Build Tools).
2. Executar o notebook `05_exploracao_bases.ipynb` até a conversão dos arquivos DBC.
3. Executar, em ordem, `06_tratamento_sim.py`, `07_tratamento_sinasc.py` e `08_dimensoes.py`.
4. Provisionar o banco com o Terraform (seção 9) e gerar o arquivo `.env` com a URI de conexão.
5. Executar `09_carga_postgres.py` e `10_validacao_carga.py`.

9. Base armazenada em banco de dados (entregável 3)

Os dados tratados estão em um PostgreSQL gerenciado na Aiven, plano gratuito, provisionado via Terraform e organizado em modelo estrela: 19 tabelas, 145 MB (14% do limite de 1 GB).

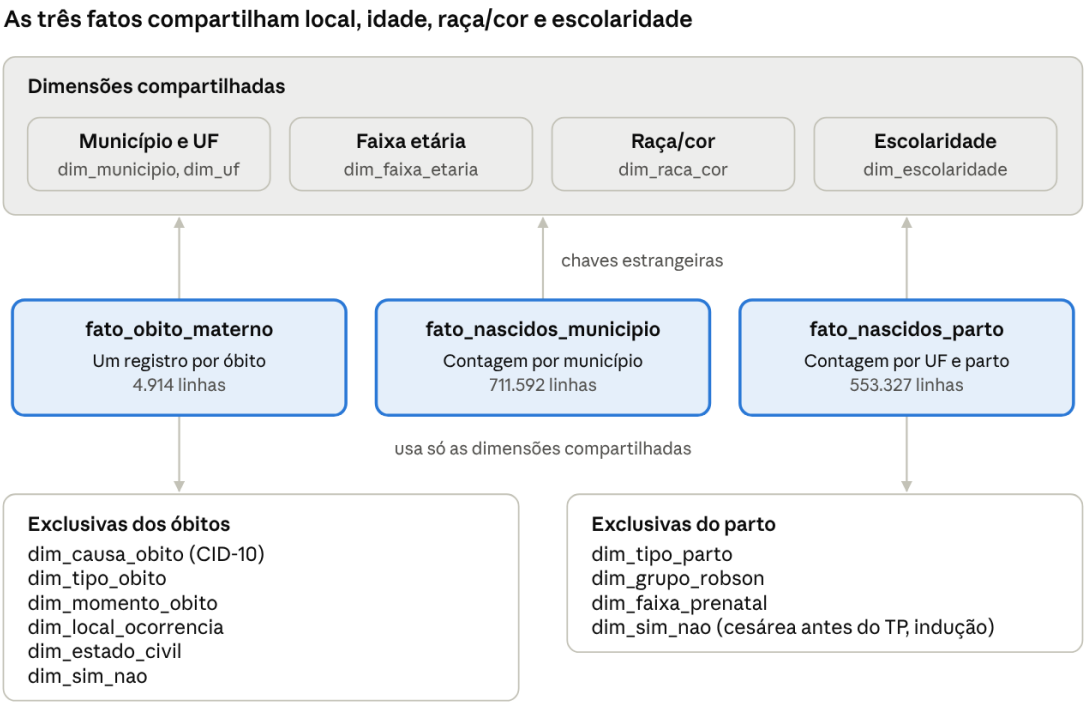
9.1 Infraestrutura

O serviço foi criado pelo Terraform (`terraform/main.tf`, `variables.tf`, `outputs.tf`), com o provider oficial da Aiven: plano `free-1-1gb` (1 CPU, 1 GB de RAM, 1 GB de armazenamento), serviço `pg-saude-materna`, região `do-nyc` (DigitalOcean, Nova York). A região foi escolhida porque o plano gratuito só existe nas nuvens DigitalOcean e UpCloud; São Paulo e AWS foram testadas e recusadas pela Aiven.

Segurança das credenciais: o token da Aiven fica em `terraform.tfvars` e a URI de conexão no `.env`, ambos fora do Git (`.gitignore`), assim como o arquivo de estado do Terraform. Os outputs com senha são marcados como sensíveis e não aparecem no terminal.

9.2 Modelo estrela

Foi escolhido um banco relacional porque os dados são estruturados, os relacionamentos são fixos e as consultas do dashboard são agregações (contagens e razões por recortes). O modelo estrela separa os fatos (o que se mede) das dimensões (os recortes), e as três tabelas fato compartilham as mesmas dimensões de local, idade, raça/cor e escolaridade, o que permite dividir óbitos por nascidos vivos em qualquer combinação desses recortes.



modelo estrela · 3 fatos, 14 dimensões

Cada seta é uma chave estrangeira: o banco recusa qualquer código que não exista na dimensão. As fatos de nascidos usam chave primária composta pelas próprias dimensões, garantindo uma linha por combinação.

9.3 Tabelas e quantidade de dados

Tabela	Tipo	Grão (o que é cada linha)	Chave primária	Linhas	Tamanho
fato_nascidos_municipio	Fato	ano × município × faixa etária × raça/cor × escolaridade	composta (5 campos)	711.592	70 MB
fato_nascidos_parto	Fato	ano × UF × faixa etária × raça/cor × escolaridade × parto × Robson × pré-natal × cesárea antes do TP ×	composta (10 campos)	553.327	65 MB

Tabela	Tipo	Grão (o que é cada linha)	Chave primária	Linhas	Tamanho
		indução			
fato_obito_materno	Fato	um óbito materno	id_obito	4.914	992 kB
dim_municipio	Dimensão	município (IBGE + 19 ignorados)	cod_mun_res	5.590	656 kB
dim_causa_obito	Dimensão	causa de óbito (CID-10)	cod_causa	269	88 kB
dim_uf	Dimensão	unidade da federação	cod_uf	27	24 kB
11 dimensões categóricas	Dimensão	códigos dos dicionários de dados	código	3 a 12 cada	24 kB cada
controle_sim, controle_sinasc	Controle	um ano processado	—	3 cada	8 kB cada
controle_carga	Controle	uma tabela carregada (linhas no CSV e no banco)	tabela	19	—

As 11 dimensões categóricas são: raça/cor, escolaridade, estado civil, local de ocorrência, momento do óbito, tipo de parto, sim/não, grupo de Robson, faixa etária, faixa de pré-natal e tipo de óbito.

9.4 Campos e tipos das tabelas fato

Campo	Tipo	Tabelas fato	Relacionamento
id_obito	INTEGER	óbitos	chave primária
ano	SMALLINT	todas	—
mes	SMALLINT	óbitos	—
data_obito	DATE	óbitos	—
idade	SMALLINT	óbitos	—
cod_mun_res	CHAR(6)	óbitos, nascidos por município	dim_municipio

Campo	Tipo	Tabelas fato	Relacionamento
cod_uf	CHAR(2)	nascidos por parto	dim_uf
faixa_etaria	VARCHAR(10)	todas	dim_faixa_etaria
cod_raca_cor	CHAR(1)	todas	dim_raca_cor
cod_escolaridade	CHAR(1)	todas	dim_escolaridade
cod_estado_civil	CHAR(1)	óbitos	dim_estado_civil
cod_local_ocorrencia	CHAR(1)	óbitos	dim_local_ocorrencia
cod_causa_basica	VARCHAR(4)	óbitos	dim_causa_obito
cod_causa_externa	VARCHAR(4)	óbitos	dim_causa_obito
cod_momento_obito	CHAR(1)	óbitos	dim_momento_obito
obito_gravidez, assistencia_medica	CHAR(1)	óbitos	dim_sim_nao
obito_puerperio	CHAR(1)	óbitos	—
tipo_obito	VARCHAR(40)	óbitos	dim_tipo_obito
entra_rmm	BOOLEAN	óbitos	—
cod_parto	CHAR(1)	nascidos por parto	dim_tipo_parto
grupo_robson	SMALLINT	nascidos por parto	dim_grupo_robson
faixa_prenatal	VARCHAR(12)	nascidos por parto	dim_faixa_prenatal
cod_cesarea_antes_tp, cod_tp_induzido	CHAR(1)	nascidos por parto	dim_sim_nao
qtd_nascidos	INTEGER	nascidos (ambas)	—

Os tipos e chaves completos de todas as tabelas estão em `etl/sql/01_schema.sql`.

10. Limitações

A base está pronta para as regras de negócio e o dashboard, mas alguns cuidados de interpretação já foram identificados.

- **Números pequenos:** em estados com poucos nascimentos, um único óbito muda muito a RMM (em Roraima, cerca de 8 pontos). O dashboard deve mostrar o número absoluto ao lado da razão e permitir somar os três anos.
- **Raça/cor em fontes diferentes:** no SIM ela é informada por familiares ou pelo médico; no SINASC, é a da mãe no nascimento. Diferenças de classificação podem distorcer a razão por raça/cor.

- **Agrupamento "negra":** a soma de pretas e pardas pode esconder diferenças entre os dois grupos; as cinco categorias foram mantidas no banco para que o dashboard mostre ambas as visões.
- **Versão da base:** o SIM é atualizado após as investigações de óbito; os números de 2022 e 2023 podem mudar levemente em novas extrações.
- **Região do banco:** o plano gratuito da Aiven só está disponível nas nuvens DigitalOcean e UpCloud, sem regiões na América do Sul; foi escolhida Nova York, a mais próxima. Os dados são públicos, anonimizados na origem e agregados no ETL, não configurando dado pessoal para a LGPD.

Um primeiro resultado interseccional, calculado no banco para 2022 a 2024: a RMM das mulheres indígenas é de 123,9 por 100 mil nascidos vivos, cerca de 2,5 vezes a das mulheres brancas (49,5); a das mulheres negras é 55,8.